

Web Mining

SELEKSI FITUR (Studi Kasus Klasifikasi Dokumen)

Prodi Teknik Informatika

Universitas Trunojoyo Madura

2024

LATAR BELAKANG

- **Dalam membangun suatu model (prediksi atau klassifikasi)**
 - Meningkatkan performansi model
 - Mendapatkan representasi dari sebuah model
 - Keterbasan sumber daya komputasi
 - Banyaknya fitur/variabel dibandingkan dengan sampel/instance
 - menyederhanakan model sehingga lebih mudah untuk diinterpretasikan oleh peneliti atau pengguna
 - Meningkatkan generalisasi model dengan cara mengurangi *overfitting*

Text	Label
Manager Kajian Kebijakan Eksekutif Nasional Walhi, Boy Jerry Even Sembiring menilai, pemindahan ibu kota ke Penajaman Paser Utara, Kalimantan Timur, tetap akan diikuti dengan beban ekologis Jakarta dan Pulau Jawa. "Pemindahan ibu kota hanya akan memindahkan beban ekologis Jakarta dan Pulau Jawa ke Kalimantan Timur dan lokasi sekitarnya," ujar Boy dalam diskusi	Negatif
Menteri Dalam Negeri Tito Karnavian meyakini pemindahan ibu kota negara ke Kalimantan akan mendongkrak perekonomian Kalimantan secara keseluruhan.	Positif
rencana pemindahan ibu kota yang diputuskan pemerintah sudah tepat. Menurut dia Jakarta memang sudah waktunya diberi ruang untuk bernapas. "Jakarta saat ini sudah terlalu rumit, baik populasinya, polusinya, tingkat kejahatannya, ketimpangan sosialnya, dan seterusnya," kata perempuan yang akrab disapa Mala itu, Selasa	Positif
. . . dst	

Klasifikasi dokumen

Dokumen	Term_1 (X1)	Term_2	...	Term_n-1	Term_n	Label (Y)
1	0.6119	0.6507	0.3215	0.7213	0.3412	Negatif
2	0.6685	0.6178	0.5128	0.2393	0.4715	Positif
3	0.4256	0.5908	0.8071	0.6702	0.4431	Positif
4	0.7273	0.7170	0.2909	0.3294	0.6603	Negatif
5	0.6754	0.5982	0.7754	0.7236	0.8239	Positif
6	0.4012	0.5566	0.1866	0.1114	0.3246	Positif
.... dsr						

Jumlah
dokumen = k

misal
Banyak term = n

$n > k$

Persoalan dalam pembelajaran mesin (contoh)

- **Klasifikasi dokumen**
 - Dokumen dinyatakan dengan **vector space model** dengan dimensi data adalah kosa kata yang ada dalam dokumen
 - Semakin banyak kosakata yang pada dokumen -> semakin tinggi dimensi variabel /fitur (jumlahnya sangat banyak atau melebihi banyaknya dokumen)


Misal:

Vocabulary ~ 15.000 kata (sehingga setiap dokumen dinyatakan dalam dengan 15.000-dimensi vektor

- **Seleksi Gen dari data microarray**
 - Variabel: koefisien ekspresi gene
 - Tujuan :untuk apat membedakan pasien sehat dari pasien penyakit kanker

PERLU.....


- Ketika jumlah variabel/fitur sangat banyak (dimensi data tinggi) maka perlu reduksi dimensi ----->**SELEKSI FITUR**
- Seleksi fitur sangat signifikan untuk meningkatkan *performance* algoritma pembelajaran
- Memilih fitur-fitur yang relevan dan menghilangkan Redundancy suatu kumpulan fitur



BUTUH

Seleksi fitur

Kerangka *Machine Learning*



Definsi masalah

- Klasifikasi (Supervised Learning):
Diberikan data pelatihan (**training data**)

$$L = \{(x_1, y_1), \dots, (x_i, y_i), \dots, (x_m, y_m)\} \in X \times Y$$

Clasifier harus menemukan **hypothesis**

$$h \in H : X \rightarrow Y$$

Yang digunakan untuk memberi y untuk data baru x .

Fitur/Variabel

- Data X terdiri dari n fitur :


$$X = f_1 \times \dots \times f_i \times \dots \times f_n$$

Seleksi fitur

- Dari fitur yang ada $F = \{ f_1, \dots, f_i, \dots, f_n \}$
Seleksi fitur adalah mencari $F' \subseteq F$
yang memaksimalkan hasil klasifikasi

Seleksi fitur

- Seleksi fitur:



$$\{f_1, \dots, f_i, \dots, f_n\} \xrightarrow{f.selection} \{f_{i_1}, \dots, f_{i_j}, \dots, f_{i_m}\}$$


$$i_j \in \{1, \dots, n\}; j = 1, \dots, m$$

$$i_a = i_b \Rightarrow a = b; a, b \in \{1, \dots, m\}$$


Seleksi Fitur

- Metode Filter
 - Metode ini mengevaluasi setiap fitur secara independen dari algoritma machine learning. Contoh teknik yang digunakan adalah korelasi Pearson, Chi-Square, dan ANOVA
- Metode Wrapper
 - Metode ini menggunakan algoritma machine learning untuk mengevaluasi kombinasi fitur dan memilih yang terbaik berdasarkan kinerja model. Contoh tekniknya adalah forward selection, backward elimination, dan recursive feature elimination
- Metode Embedded
 - Metode ini mengintegrasikan proses seleksi fitur ke dalam pelatihan model. Contoh tekniknya adalah Lasso Regression dan Decision Trees


Seleksi Fitur



Metode Filter



Metode Wrapper




Metode Embedded

Seleksi Fitur

- memilih kualitas fitur atau fitur yang optimal didasarkan pada
 - **ukuran informasi (information measures)** ,
 - ukuran jarak (distance measures),
 - **ukuran kebergantungan (dependence measures),**
 - ukuran kekonsistenan (consistency measures).
- Metode filter dilakukan terpisah dari model pembelajaran proses pemilihan fitur dilakukan sebelum tahapan pembelajaran model.
- Metode ini juga disebut dengan metode pemeringkatan fitur. Setelah melakukan pemeringkatan nilai ukuran, dipilih fitur berdasarkan batas ambang yang ditentukan,

Merangking fitur/variable ranking

- Dari fitur F
Variable Ranking adalah proses mengurutkan nilai dari fungsi skore (yang mengukur relevansi fitur) $S:F \rightarrow \mathbb{R}$
- Skor tinggi menyatakan fitur yang relevan.



Metode filter

- Jenis teknik seleksi fitur, diantaranya adalah
 - **Mutual/Information Gain** (Kullback–Leibler divergence),
 - *Chi-Squared*,
 - ANOVA (*Analysis of Variance*), dll.

Information Gain

- *Information Gain* dalam machine learning digunakan untuk mengukur seberapa relevan / berpengaruh sebuah feature terhadap hasil pengukuran.
- Pengukuran didasarkan pada Entropy sebelum dan sesudah pemisahan.
- *Information Gain (IG)* dikenal juga dengan sebutan ***Mutual Information (MI)*** dalam kasus untuk mengetahui dependency antara dua variable (x,y).

Procedure Information Gain data mining feature selection Algorithm (IGFS)

```
var1  sf1  /* store selected feature. Initially empty*/
var2  Th   /* hold threshold value*/
var3  f(i) /* contains the ith feature of the data set */
1: begin
2: IGFS.build ();
3: begin
4:   sf1 = {}; /* create array of var1*/
5:   for loop i=1 to int of features
6:     INF=compute (IG) for the feature /* store computed features*/
7:     Gain (i) =INF /* compute Gain (i) */
8:   end for
9:   Th= threshold value /* hold threshold value*/
10:  For i= 1 to number of features
11:    If gain (i) > Th then
12:      Sf1=sf1+f {i} /* store and compute every feature in dataset*/
13:    end if
14:  end for
15: end
```

Sumber:

https://www.researchgate.net/publication/340099203_A_Composite_Hybrid_Feature_Selection_Learning-Ba

MUTUAL INFORMATION

$$I(X, Y) = \sum_{x \in X} \sum_{y \in Y} P(x, y) \log \left(\frac{P(x, y)}{P(x) P(y)} \right)$$

dimana X dan Y adalah variabel

$P(x)$, $P(y)$, dan $P(x, y)$ adalah probabilitas

Jika X adalah kontinu dan Y adalah diskrit

$$I(X, Y) = H(X) + \sum_{i=1}^k p(Y = i) H(X|Y = i)$$

$H(X)$ adalah entropy

$$H(X) = - \sum_{i=1}^n P(x_i) \log P(x_i)$$

Vector Space Model

term_1	term_2	term_3	term_4	Opini
255	0	0	3	positif
255	255	10	16	positif
20	255	50	10	negatif
50	255	235	76	negatif
0	50	255	0	negatif
50	245	60	34	negatif
234	50	0	11	positif
0	10	235	21	positif
0.20	0.06	0.10	0.00	MI

Seleksi fitur

term_1	term_2	term_3	Opini
255	0	0	positif
255	255	10	positif
20	255	50	negatif
50	255	235	negatif
0	50	255	negatif
50	245	60	negatif
234	50	0	positif
0	10	235	positif
0.20	0.06	0.10	MI



term_4 dihapus
karena tidak
relevan

```
selector = SelectKBest(mutual_info_classif, k=3)
```

Membagi data latih dan uji

term_1	term_2	term_3	Opini
255	0	0	positif
255	255	10	positif
20	255	50	negatif
50	255	235	negatif
0	50	255	negatif
50	245	60	negatif
234	50	0	positif
0	10	235	positif

```
X_train, X_test, y_train, y_test = train_test_split(X_fitur_baru, y, test_size=0.2, random_state=0)
```

Performansi Model

Confusión Matrix		PREDICTED PATTERNS	
		0	1
ACTUAL PATTERNS	0	True Positives TP	False Negatives FN
	1	False Positives FP	True Negatives TN

$$recall = \frac{TP}{TP + FN}$$

$$precision = \frac{TP}{TP + FP}$$

$$F1Score = 2 * \frac{precision * recall}{precision + recall}$$

$$Accuracy = \frac{\sum TP + TN}{\sum TP + FP + FN + TN}$$

<https://medium.com/@kohlishivam5522/understanding-a-classification-report-for-your-machine-learning-model-88815e2ce397>

<https://towardsdatascience.com/multi-class-metrics-made-simple-part-i-precision-and-recall-9250280bddc2>

Apa Itu Chi-Square?

- **Chi-Square (χ^2)** adalah sebuah tes statistik yang digunakan untuk menentukan apakah terdapat hubungan yang signifikan antara dua variabel kategorikal. Dalam konteks **feature selection** pada **klasifikasi teks**, Chi-Square digunakan untuk mengukur sejauh mana frekuensi kemunculan suatu fitur (misalnya, kata tertentu) berhubungan dengan kelas target (misalnya, ulasan positif atau negatif).
- Dengan kata lain, Chi-Square membantu kita menentukan fitur mana yang paling relevan untuk memisahkan antara kelas-kelas yang berbeda.
- Ia berfungsi ketika nilai fitur adalah frekuensi (term, misalnya) karena jumlahnya akan menjadi frekuensi total fitur (term) di kelas tersebut. Tidak ada diskretisasi yang terjadi.
- Ia juga bekerja cukup baik dalam praktiknya ketika nilainya adalah nilai tf-idf, karena itu hanya frekuensi yang dibobot/diskalakan.

Mengapa Menggunakan Chi-Square untuk Feature Selection?

- **Relevansi Fitur:** Membantu mengidentifikasi fitur (kata) yang paling berpengaruh dalam membedakan antara kelas target.
- **Mengurangi Dimensi:** Dengan memilih fitur yang paling relevan, kita dapat mengurangi jumlah fitur yang digunakan dalam model, yang dapat meningkatkan efisiensi dan performa model.
- **Mencegah Overfitting:** Fitur yang kurang relevan atau berisik dapat menyebabkan model overfit. Seleksi fitur membantu mengurangi risiko ini.

Langkah-Langkah Perhitungan Chi-Square

- **Membangun Kontingensi Tabel**
- Contoh : Untuk setiap fitur (kata), kita membangun sebuah tabel kontingensi 2x2 yang menggambarkan frekuensi kemunculan fitur tersebut di masing-masing kelas. Misalnya, kita memiliki dua kelas: **Positif** dan **Negatif**.

Langkah-Langkah Perhitungan Chi-Square

- A: Jumlah dokumen positif yang mengandung kata tersebut.
- B: Jumlah dokumen negatif yang mengandung kata tersebut.
- C: Jumlah dokumen positif yang tidak mengandung kata tersebut.
- D: Jumlah dokumen negatif yang tidak mengandung kata tersebut. N: Total jumlah dokumen ($A + B + C + D$).

	Positif	Negatif	Total
Mengandung Kata	A	B	$A + B$
Tidak Mengandung	C	D	$C + D$
Total	$A + C$	$B + D$	N

Menghitung Nilai Chi-Square

- Rumus Chi-Square untuk tabel kontingensi 2x2 adalah sebagai berikut:

$$\chi^2 = \frac{N \times (A \times D - C \times B)^2}{(A + C) \times (B + D) \times (A + B) \times (C + D)}$$

- Dimana:
 - **$N = A + B + C + D$**

Menentukan Relevansi Fitur

- Setelah menghitung nilai Chi-Square untuk setiap fitur, kita dapat menentukan fitur mana yang paling relevan berdasarkan nilai Chi-Square tertinggi.

Contoh Perhitungan Chi-Square

- Untuk memberikan pemahaman yang lebih jelas, mari kita lakukan perhitungan Chi-Square untuk salah satu fitur, misalnya "**Buruk**".
- Membangun Kontingensi Tabel untuk Fitur "Buruk" :
 - Misalkan kita memiliki data sebagai berikut:
 - **Total Dokumen Positif (Pos): 100**
 - **Total Dokumen Negatif (Neg): 100**
 - **Dokumen Positif yang Mengandung "Buruk" (A): 5**
 - **Dokumen Negatif yang Mengandung "Buruk" (B): 20**
 - **Dokumen Positif yang Tidak Mengandung "Buruk" (C): 95**
 - **Dokumen Negatif yang Tidak Mengandung "Buruk" (D): 80**
 - **Total Dokumen (N): 200**

Contoh Perhitungan Chi-Square

	Positif	Negatif	Total
Mengandung "Buruk"	5	20	25
Tidak Mengandung	95	80	175
Total	100	100	200

- Nilai Chi-Square sebesar 10.29 menunjukkan bahwa ada hubungan yang signifikan antara kata "Buruk" dengan kelas target (positif atau negatif).
- Semakin tinggi nilai Chi-Square, semakin kuat hubungan antara fitur dan kelas target.
- Interpretasi :Dalam contoh ini, nilai Chi-Square untuk kata "Buruk" adalah 10.29, yang menunjukkan bahwa kata ini sangat relevan dalam membedakan antara ulasan positif dan negatif. Oleh karena itu, kata "Buruk" harus dipertahankan sebagai fitur dalam model klasifikasi.

$$\chi^2 = \frac{200 \times (5 \times 80 - 95 \times 20)^2}{(5 + 95) \times (20 + 80) \times (5 + 20) \times (95 + 80)}$$

$$\chi^2 = \frac{200 \times (400 - 1900)^2}{100 \times 100 \times 25 \times 175}$$

$$\chi^2 = \frac{200 \times (-1500)^2}{100 \times 100 \times 25 \times 175}$$

$$\chi^2 = \frac{200 \times 2,250,000}{43,750,000}$$

$$\chi^2 = \frac{450,000,000}{43,750,000} \approx 10.29$$